

DualGuard 개발 현황

듀얼렌즈(DualLens) 팀 · 통화·화상통화 사기 교차분석 · KDT 본선

저장소 github.com/DBR-real-project/dual-renz (main, 워킹 트리 clean)
규모 소스 22파일 4,975줄 · 스크립트 38개 · 문서 6개 + 실측 리포트 18개
정리일 2026-08-18 (2차 — 확장 activeTab 해결, 음성 원인 규명, 모델 비교 반영)

1. 무엇을 만들었나

통화 파일	STT (faster-whisper) → 8대 사회공학 기법 분류 + RAG 음성 → AASIST 합성 판별 영상 → FF++ Xception 얼굴 위조 판별	콘텐츠 위험도 미디어 위험도	Fraud Risk Score 교차 가산
-------	--	--------------------	---------------------------

↓ 신호등 + 구간별 타임라인 + 3단계 액션 플랜

기획서 본선 범위(Phase 1)는 전부 구현됐고, 원래 범위 밖이던 Phase 2(실시간 스트리밍 + 크롬 확장)까지 완료했다.

기능	상태
웹 대시보드 (업로드 → 진행률 → 결과)	업로드·WebSocket 진행률·이중 라인 그래프·근거 표시
CLI 전체 분석	<code>analyze_call.py</code> 한 줄로 전체 파이프라인
분석 히스토리	디스크 저장, 서버 재시작 후에도 열람·삭제 + 위험도 추이 그래프
실시간 스트리밍	세션 API, 모델 상주 + 청크 누적. 오디오 78초를 26초에 처리(3배속)
크롬 확장 (MV3)	실제 크롬에서 전 과정 자동 검증 통과. 확장 단축키를 OS 레벨로 눌러 <code>activeTab</code> 을 정식으로 부여받는다 — 우회 없음
키 없이 도는 로컬 LLM	<code>DUALGUARD_LLM_PROVIDER=local</code> — API 키도 별도 설치도 불필요

2. 실측 수치

발표에 자신 있게 쓸 수 있는 것

엔진	정탐	오탐	정확도	표본
음성 (AASIST)	97.1%	0.0%	98.3%	ASVspoof 120건
콘텐츠 (오프라인 분류기)	90.9%	10.0%	90.5%	자체 구성 21건
콘텐츠 도메인 밖 오탐	—	1.53%	—	우리가 안 만든 한국어 457문장
실제 보이스피싱 녹취	5/5 탐지	—	—	금감원 「그놈 목소리」

마지막 두 줄이 가장 강한 근거다. 우리가 만든 데이터가 아니다. 공개 코퍼스 457문장에서 헛정보 1.53%, 그리고 금융감독원이 공개한 실제 사기범 통화 녹취 5건을 전부 탐지했다.

조건 없이 인용하면 무너지는 것

① 영상 엔진 — 학습 도메인 밖에서 붕괴한다

데이터셋	정탐	오탐	정확도
FaceForensics++ (학습 도메인, 116건)	77.3%	2.0%	86.2%
DFDC (다른 데이터셋, 50건)	70.0%	55.0%	60.0%

진짜/가짜 점수 분포가 겹친다(48.5 vs 58.0). 공개 딥페이크 모델 4종을 같은 조건에서 재봤는데 전부 더 나뻐다 — DFDC 분리도 +7.3 / +0.5 / -2.1 / -17.6, 오탐 50~100%. (우리는 +9.4) 음수는 진짜를 가짜보다 높게 준다는 뜻이다. 모델 교체로는 풀리지 않는다.

발표에서 영상 수치를 말할 때는 반드시 "FF++ 기준"을 붙일 것.

② 음성 엔진 — 같은 문제를 공유한다 (원인 규명 완료)

실제 사기 통화 5건에서 미디어 위험도가 전부 100이었다 — 사람이 직접 말한 통화인데도. 코덱·전화망·재인 코딩·편집을 하나씩 통제 실험으로 배제하고, 음량을 통일해 비교하니 답이 나왔다:

그룹	-39dB	-30dB	-25dB	-20dB
ASVspoof 진짜 (학습 도메인)	0.8	0.4	0.2	0.3
Zeroth 낭독 (도메인 밖)	16.9	81.1	98.9	100.0
실제 통화 녹취 (도메인 밖)	45.4	98.1	100.0	100.0

학습 도메인 안에서는 음량과 무관하게 안정적인데, 도메인 밖 진짜 음성은 음량이 올라가면 합성으로 판정된다. 음량은 방아쇠일 뿐 근본 원인은 영상과 똑같은 일반화 실패다. 초록 시연 샘플이 낮은 점수인 것도 "진짜 목소리라서"가 아니라 "조용해서"(-39dB)다.

3. 실측으로 확인한 설정

기획서 두 벌이 서로 다르거나 근거 없이 잡아뗐던 값들을 **전부 스크립트로 재서** 확인했다. 바꾸려면 해당 스크립트를 다시 돌려 반박 데이터를 내야 한다.

항목	확인값	근거
통합 공식	DOCX 버전 (multiplicative)	정확도는 동물인데 PDF 버전은 임계값에서 점수가 +15.2 계단 으로 튜다
가중치	콘텐츠 0.65 / 미디어 0.35	사기를 '낮음'으로 놓치는 건수 84 → 21건, 헛경보 0 유지
신호등 경계	높음 55 / 중간 30	756개 조합 스왑에서 최적
딥페이크 임계값	결정 항목 자체를 제거	점수를 재척도해 50 하나만 사용. 최적 임계값이 정확히 50에 온다
오디오·영상 결합	max 유지	가중평균은 한쪽만 위조된 경우 4조합 중 2개를 놓친다
얼굴 검출기	YuNet (Haar 풀백)	30° 회전에서 검출률 34% → 100%, 판정 불가 영상 13개 → 0개
좌우 반전 TTA	켄	정탐 77.3 → 80.3%, 오탐 동일
STT 모델	파일 small / 스트리밍 base	5dB 소음 CER 0.34 vs 0.56, 스트리밍은 3.1배 빠른 쪽이 필요

주의 — 가중치·신호등은 콘텐츠 21건 × 음성 50건을 교차한 합성 격자(1,050쌍)로 골랐다. 실제 통화가 아니고 두 축이 독립이라 가정했다. **설정 비교용으로만 유효**하며 격자 정확도(75.3%)를 제품 성능으로 인용하면 안 된다.

4. 진짜 남은 것 — 3개

항목	상태 / 필요한 것
상용 LLM 실제 정확도	API 키만 있으면 됨. 연동 경로는 스텝 서버로 검증했고, 로컬 LLM(Qwen2.5-1.5B)으로 대체 측정까지 완료
미디어 두 엔진의 일반화	원인까지 규명했고 공개 대안 모델도 전부 재봤다 . 통화 도메인 데이터로 미세조정하거나 비공개 최신 모델이 필요하다 — 이번 대회 범위 밖
정상 통화 녹취	사기 통화는 금감원 공개 자료로 해결했으나 정상 통화 녹취는 공개된 게 없다 . 그래서 실제 통화에서의 오탐률만 아직 못 잰다

5. 발표 준비 시 참고

`docs/demo_guide.md` 에 심사장 대본이 다 들어 있다 — 시연 순서(빨강 → 초록 → 노랑), 예상 질문 답변, 하지 말아야 할 것.

이 두 가지는 먼저 밝히는 편이 유리하다

약점	이렇게 돌린다
영상 엔진 크로스도메인 붕괴	"그래서 이름이 듀얼가드 입니다. 음성과 화법이라는 독립적인 두 축이 함께 판단합니다. 영상은 가중치 0.35 중 일부이고, 신뢰할 수 없다는 경고를 항상 함께 띄웁니다."
검증셋이 자체 제작	"우리가 만들지 않은 한국어 457문장에서 헛경보 1.53%를 따로 잰습니다. 금감원 공개 실제 녹취 5건은 5/5 탐지했습니다."

가장 강한 한 문장

금감원 공개 녹취 5건은 전부 **사람이 직접 말한 통화**다. 즉 **딥페이크 탐지만 하는 솔루션은 이 5건을 하나도 못 잡는다**. 대화 내용을 함께 보는 이유가 여기 있다.

성능 수치의 측정 조건은 `docs/validation_report.md` 참고. 남은 작업과 해결 방법은 `docs/blocked_and_next.md`. 시연 담당자는 `docs/demo_guide.md` 부터.