

DualGuard 개발 현황

듀얼렌즈(DualLens) 팀 · 통화·화상통화 사기 교차분석 · KDT 본선

저장소 github.com/DBR-real-project/dual-renz (main, 워킹 트리 clean)
규모 소스 22파일 4,975줄 · 스크립트 38개 · 문서 6개 + 실측 리포트 18개
정리일 2026-08-18

1. 무엇을 만들었나

통화 파일	STT (faster-whisper) → 8대 사회공학 기법 분류 + RAG 음성 → AASIST 합성 판별 영상 → FF++ Xception 얼굴 위조 판별	콘텐츠 위험도 미디어 위험도	Fraud Risk Score 교차 가산
-------	--	--------------------	---------------------------

↓ 신호등 + 구간별 타임라인 + 3단계 액션 플랜

기획서 본선 범위(Phase 1)는 전부 구현됐고, 원래 범위 밖이던 Phase 2(실시간 스트리밍 + 크롬 확장)까지 완료했다.

기능	상태
웹 대시보드 (업로드 → 진행률 → 결과)	업로드·WebSocket 진행률·이중 라인 그래프·근거 표시
CLI 전체 분석	<code>analyze_call.py</code> 한 줄로 전체 파이프라인
분석 히스토리	디스크 저장, 서버 재시작 후에도 열람·삭제 + 위험도 추이 그래프
실시간 스트리밍	세션 API, 모델 상주 + 청크 누적. 오디오 78초를 26초에 처리(3배속)
크롬 확장 (MV3)	실제 크롬에 로드해 캡처→분석→오버레이까지 자동 검증 통과
키 없이 도는 로컬 LLM	<code>DUALGUARD_LLM_PROVIDER=local</code> — API 키도 별도 설치도 불필요

2. 실측 수치

발표에 자신 있게 쓸 수 있는 것

엔진	정탐	오탐	정확도	표본
음성 (AASIST)	97.1%	0.0%	98.3%	ASVspoof 120건
콘텐츠 (오프라인 분류기)	90.9%	10.0%	90.5%	자체 구성 21건
콘텐츠 도메인 밖 오탐	—	1.53%	—	우리가 안 만든 한국어 457문장
실제 보이스피싱 녹취	5/5 탐지	—	—	금감원 「그놈 목소리」

마지막 두 줄이 가장 강한 근거다. 우리가 만든 데이터가 아니다. 공개 코퍼스 457문장에서 헛경보 1.53%, 그리고 금융감독원이 공개한 실제 사기범 통화 녹취 5건을 전부 탐지했다.

조건 없이 인용하면 무너지는 것

① 영상 엔진 — 학습 도메인 밖에서 붕괴한다

데이터셋	정탐	오탐	정확도
FaceForensics++ (학습 도메인, 116건)	77.3%	2.0%	86.2%
DFDC (다른 데이터셋, 50건)	70.0%	55.0%	60.0%

진짜/가짜 점수 분포가 겹친다(48.5 vs 58.0). c40 가중치로 바꾸면 더 나쁘다(오탐 90%). 발표에서 영상 수치를 말할 때는 반드시 "FF++ 기준"을 붙일 것.

② 음성 엔진 — 실제 녹취를 합성으로 오판한다

실제 사기 통화 5건에서 미디어 위험도가 전부 100이었다. 사람이 직접 말한 통화인데도. 통제 실험으로 추적한 결과:

조건	AASIST 점수
스튜디오 원본 (16kHz)	16.5
G.711 전화망 (300~3400Hz + 8kHz + μ -law)	6.5
실제 공개 녹취	100.0

전화망도 코덱도 원인이 아니다 — 오히려 점수가 내려간다. 편집·마스킹·화자 혼합이 의심되지만 원인은 미규명이다.

3. 실측으로 확인한 설정

기획서 두 벌이 서로 다르거나 근거 없이 잡아뗐던 값들을 **전부 스크립트로 재서** 확인했다. 바꾸려면 해당 스크립트를 다시 돌려 반박 데이터를 내야 한다.

항목	확인값	근거
통합 공식	DOCX 버전 (multiplicative)	정확도는 동물인데 PDF 버전은 임계값에서 점수가 +15.2 계단 으로 튜다
가중치	콘텐츠 0.65 / 미디어 0.35	사기를 '낮음'으로 놓치는 건수 84 → 21건, 헛경보 0 유지
신호등 경계	높음 55 / 중간 30	756개 조합 스왑에서 최적
딥페이크 임계값	결정 항목 자체를 제거	점수를 재척도해 50 하나만 사용. 최적 임계값이 정확히 50에 온다
오디오·영상 결합	max 유지	가중평균은 한쪽만 위조된 경우 4조합 중 2개를 놓친다
얼굴 검출기	YuNet (Haar 풀백)	30° 회전에서 검출률 34% → 100%, 판정 불가 영상 13개 → 0개
좌우 반전 TTA	켄	정탐 77.3 → 80.3%, 오탐 동일
STT 모델	파일 small / 스트리밍 base	5dB 소음 CER 0.34 vs 0.56, 스트리밍은 3.1배 빠른 쪽이 필요

주의 — 가중치·신호등은 콘텐츠 21건 × 음성 50건을 교차한 합성 격자(1,050쌍)로 골랐다. 실제 통화가 아니고 두 축이 독립이라 가정했다. **설정 비교용으로만 유효**하며 격자 정확도(75.3%)를 제품 성능으로 인용하면 안 된다.

4. 진짜 남은 것 — 4개

항목	상태 / 필요한 것
확장 <code>activeTab</code> 클릭 확인	크롬이 사람의 실제 클릭에만 권한을 준다. 자동화로는 합성 불가. <code>node scripts/verify_extension_chrome.js --manual</code> — 10초면 끝
상용 LLM 실제 정확도	API 키만 있으면 됨. 연동 경로는 스텝 서버로 검증했고, 로컬 LLM(Qwen2.5-1.5B)으로 대체 측정까지 완료
영상 엔진 일반화	측정은 끝났고 결과가 나뉘었다 . 2019년 체크포인트를 교체하지 않으면 개선 안 됨
정상 통화 녹취	사기 통화는 금감원 공개 자료로 해결했으나 정상 통화 녹취는 공개된 게 없다 . 그래서 실제 통화 오탐률을 못 재고, 음성 엔진 오작동 규명도 막혀 있다

5. 발표 준비 시 참고

`docs/demo_guide.md` 에 심사장 대본이 다 들어 있다 — 시연 순서(빨강 → 초록 → 노랑), 예상 질문 답변, 하지 말아야 할 것.

이 두 가지는 먼저 밝히는 편이 유리하다

약점	이렇게 돌린다
영상 엔진 크로스도메인 붕괴	"그래서 이름이 듀얼가드 입니다. 음성과 화법이라는 독립적인 두 축이 함께 판단합니다. 영상은 가중치 0.35 중 일부이고, 신뢰할 수 없다는 경고를 항상 함께 띄웁니다."
검증셋이 자체 제작	"우리가 만들지 않은 한국어 457문장에서 헛경보 1.53%를 따로 잰습니다. 금감원 공개 실제 녹취 5건은 5/5 탐지했습니다."

가장 강한 한 문장

금감원 공개 녹취 5건은 전부 **사람이 직접 말한 통화**다. 즉 **딥페이크 탐지만 하는 솔루션은 이 5건을 하나도 못 잡는다**. 대화 내용을 함께 보는 이유가 여기 있다.

성능 수치의 측정 조건은 `docs/validation_report.md` 참고. 남은 작업과 해결 방법은 `docs/blocked_and_next.md`. 시연 담당자는 `docs/demo_guide.md` 부터.