

딥페이크 탐지 정확도와 가중치 근거

듀얼렌즈(DualLens) 팀 · 듀얼가드(DualGuard) · 멘토링 자료 · 2026-08-18

서비스 — 통화·화상통화를 넣으면 ① **대화 화법**(8대 사회공학 기법)과 ② **음성·영상의 진위**를 각각 분석해, 두 신호를 교차 검증한 하나의 Fraud Risk Score(0~100)로 통합합니다.

여쭙고 싶은 것

— 아래 두 가지를 실측 데이터를 놓고 봐주셨으면 합니다.

① 딥페이크 탐지가 **학습 데이터 밖에서 무너지는 문제**를 이 상태로 제품에 넣는 게 맞는지

② 콘텐츠·미디어 **가중치 0.65 / 0.35를 정한 방법**이 타당한지 (합성 격자 사용)

1. 딥페이크 탐지 — 지금 성능

모델: FaceForensics++ 공식 Xception 베이스라인(2019 체크포인트). 얼굴 크롭 전용. 영상당 1fps 샘플링 → 프레임 별 점수 → 상위 k개 평균으로 집계.

데이터셋	정탐률	오탐률	정확도	비고
FaceForensics++ (학습 도메인, 116건)	77.3%	2.0%	86.2%	진짜 50 / 가짜 66
↳ 좌우 반전 TTA 적용	80.3%	2.0%	87.9%	오탐 증가 없이 정탐만 상승
DFDC (다른 데이터셋, 50건)	70.0%	55.0%	60.0%	진짜 20 / 가짜 30

조작 기법별로 보면 (FF++, 임계값 50)

조작 기법	탐지	평균 점수	학습 여부
Deepfakes	11/11	100.0	학습함
Face2Face	11/11	100.0	학습함
FaceSwap	11/11	100.0	학습함
DeepFakeDetection	10/11	87.3	부분
FaceShifter	5/11	35.3	미학습(2020~)
NeuralTextures	3/11	20.5	미학습

학습한 3개 기법은 전부 100점으로 확실히 잡습니다. 놓치는 건 체크포인트 이후에 나온 기법들입니다.

2. ⚠ 핵심 문제 — 학습 데이터 밖에서 무너지다

DFDC에서 오탐률이 2% → 55%로 뛩니다. 진짜 영상 평균 48.5점 / 가짜 평균 58.0점으로 분포가 거의 겹칩니다. 임계값을 어디에 두어도 쓸 만한 지점이 없습니다(최적점에서도 오탐 60%).

가중치를 c40(고압축 학습본)으로 바꾸면 더 나빠집니다 — 오탐 90%. "DFDC가 압축이 심하니 c40이 맞을 것"이라는 가설이 반대로 나왔습니다.

개선 시도 — 세 가지를 했고 전부 실측했습니다

시도	결과
얼굴 검출기 교체 (Haar → YuNet)	30° 회전 프레임에서 검출률 34% → 100% . 판정 불가 영상 13개 → 0개. 속도는 동일(88ms vs 90ms)
점수 재척도 (로짓 1차 변환)	원점수가 0/100에 몰려 임계값이 불안정했음. 판정 경계를 50에 맞춰 정탐 66.7% → 75.8% (5-겹 교차검증), 오탐 2% 유지
좌우 반전 TTA	정탐 77.3% → 80.3% , 오탐 동일. FaceShifter 4/11 → 6/11

모델을 바꾸면 되는지도 재봤습니다

공개 딥페이크 탐지 모델 4종에 같은 얼굴 크롭을 넣어 비교했습니다. 지표는 분리도(가짜 평균 - 진짜 평균) — 정확도는 임계값에 좌우되지만 분리도는 모델이 실제로 두 부류를 구분하는지 보여줍니다.

모델	FF++ 분리도	DFDC 분리도	DFDC 오탐
FF++ Xception (현재 사용)	+66.8	+9.4	55%
dima806/deepfake_vs_real_image_detection	+18.0	+7.3	90%
Wwolf/ViT_Deepfake_Detection	+18.1	+0.5	100%
prithivMLmods/open-deepfake-detection	+4.2	-2.1	50%
prithivMLmods/Deep-Fake-Detector-v2	+19.1	-17.6	100%

음수 분리도는 진짜를 가짜보다 높게 준다는 뜻입니다(판정이 뒤집힘). 후보 중 교체할 가치가 있는 모델이 없었습니다.

질문 ① — 공개 모델 전반이 도메인 밖에서 이런 상태라면, **(a)** 영상 판별을 제품에서 빼는 게 맞는지, **(b)** 지금처럼 경고를 달아 보조 지표로만 두는 게 맞는지, **(c)** 저희 규모에서 미세조정 외에 현실적인 방법이 있는지 의견을 듣고 싶습니다.

덧붙여, **분리도를 핵심 지표로 삼은 판단**이 적절한지도 봐주시면 감사하겠습니다.

3. 가중치 0.65 / 0.35 — 어떻게 정했나

최종 점수는 $0.65 \times \text{콘텐츠} + 0.35 \times \text{미디어} + \text{교차 보너스}$ 입니다. 이 비율을 감이 아니라 스윙으로 정했습니다 (`scripts/decide_scoring.py`).

방법

콘텐츠와 미디어가 동시에 라벨링된 통화 데이터가 없어서, 각각 실측된 점수를 교차해 격자를 만들었습니다.

구성	내용
격자	콘텐츠 21건 × 음성 50건 = 1,050쌍
정답 라벨	콘텐츠가 사기 → 높음 / 정상+매체 합성 → 중간 / 정상+매체 진짜 → 낮음
탐색	공식 2종 × 가중치 9종 × 신호등 경계 조합 = 756개
선택 기준	① 농침(사기를 '낮음') 최소 → ② 헛경보 최소 → ③ 정확도

결과

설정	가중치	신호등	정확도	농침	헛경보
이전 기본값	0.50 / 0.50	70 / 40	63.2%	84	0
확정값	0.65 / 0.35	55 / 30	75.3%	21	0

농침이 84건 → 21건으로 줄고 헛경보는 0을 유지합니다. 21건은 이 격자에서 더 못 줄이는 하한이었습니다.

통합 공식도 같이 정했습니다

기획서 두 벌에 서로 다른 공식이 적혀 있었습니다. 정확도는 사실상 동물이었는데 연속성에서 같렸습니다 — 입력을 69.9 → 70.1로 0.2만 움직였을 때:

공식	점수 변화	판정
버전 A (임계값 도달 시 +15 일괄)	+15.20	계단이 생김
버전 B (두 점수의 곱에 비례)	+0.24	매끄러움

기획서가 "확률적 표현으로 과신 방지"를 원칙으로 삼았는데 임계값 하나 넘었다고 15점이 뛰면 그 원칙과 충돌한다고 판단해 버전 B를 택했습니다.

이 방법의 한계 — 저희가 스스로 걸리는 부분입니다

- 실제 통화 1,050건이 아닙니다. 실측 점수 두 축을 교차한 합성 격자이고, 콘텐츠와 매체 위조가 서로 독립이라고 가정했습니다.
- 정답 라벨을 "콘텐츠가 사기면 높음"으로 정의했기 때문에, 콘텐츠 가중치가 높게 나온 결과가 부분적으로 설계에 내재합니다. 즉 결론이 가정을 되돌려주는 구조일 수 있습니다.
- 격자에서 나온 정확도(75.3%)는 설정 비교용이지 제품 성능이 아닙니다.

덧붙임 — 멘토링 후 확보한 독립 증거

가중치를 합성 격자로 정한 게 걸려서, 전혀 다른 실제 대화 데이터로 확인했습니다. 한국어 자유대화 30건 (KsponSpeech)을 전체 파이프라인에 넣었습니다. 전부 일상 대화라 '낮음'이 아니면 헛경보입니다.

항목	결과
최종 등급 헛경보 ('중간' 이상)	7/30 = 23.3%
그중 '높음'	0/30 = 0.0%
콘텐츠(화법) 단독	1/30 = 3.3%
미디어(음성) 단독	6/30 = 20.0%

합성 격자가 가리킨 방향과 실제 데이터가 일치했습니다 — 콘텐츠가 훨씬 안정적이고 (3.3% vs 20.0%), 헛경보의 주범은 미디어 쪽입니다. 가중치를 콘텐츠에 더 준 판단은 독립적으로도 뒷받침됩니다. 다만 KsponSpeech는 대면 대화라 전화망 대역·코덱이 없어 실제 통화보다 유리한 조건입니다.

질문 ② — 두 신호가 동시에 라벨링된 데이터가 없을 때 가중치를 정하는 더 나은 방법이 있을까요? 특히 **정답 라벨 정의가 결론을 끌고 가는 순환**을 어떻게 끊는지 궁금합니다. 합성 격자 대신 쓸 만한 접근(예: 사용자 비용 함수, 소량 실데이터 검증 등)이 있다면 조언 부탁드립니다. 위 덧붙임처럼 **독립 데이터로 교차 확인하는 방식**이 충분한 검증이 되는지도 봐주시면 좋겠습니다.

4. 참고 — 나머지 엔진 성능

엔진	정탐	오탐	정확도	표본
음성 위조 (AASIST)	97.1%	0.0%	98.3%	ASVspoof 120건
대화 화법 분류	90.9%	10.0%	90.5%	자체 구성 21건
↳ 도메인 밖 헛경보	—	1.53%	—	공개 코퍼스 457문장
실제 보이스피싱 녹취	5/5 탐지	—	—	금감원 「그놈 목소리」

음성 엔진도 같은 문제를 공유합니다. 음량을 통일해 비교하면 학습 도메인 (ASVspoof)에서는 0점대로 안정적인데, 도메인 밖 진짜 음성은 음량이 올라갈수록 합성으로 판정됩니다(실제 통화 녹취 -20dB에서 100점). 원인은 규명했고 결과 화면에 경고를 항상 띄우도록 했습니다.

그래서 최종 판단은 대화 내용 쪽이 주도하도록 설계했습니다. 실제 녹취 5건을 잡은 것도 화법 분석이고, 그 5건은 전부 사람이 직접 말한 통화라 딥페이크 탐지만 하는 방식으로는 하나도 잡히지 않습니다.

모든 수치는 재현 스크립트가 있습니다 — `validate_detector.py` (영상) · `calibrate_deepfake.py` (재척도) · `compare_deepfake_models.py` (모델 비교) · `decide_scoring.py` (가중치) · `diagnose_audio_fp.py` (음성 원인). 측정 조건은 `docs/validation_report.md`.