

DualGuard — 발표용 실측 수치표

듀얼렌즈(DualLens) · 2026-09-02 기준 · 제8회 K-디지털 트레이닝 해커톤 자유과제

이 문서의 모든 숫자는 저장소의 검증 리포트에서 그대로 뽑은 값이다. 출처 파일명을 각 표에 적어줬으니, 질문이 들어오면 그 파일을 열어 보여주면 된다.

인용 원칙 — 이것만 지키면 질의응답에서 안 무너진다

정확도만 말하지 말고 “몇 건에서”를 항상 붙인다. 표본이 작은 항목이 많다.

영상 수치는 반드시 “FF++ 기준”을 함께 말한다. 다른 데이터셋에서는 무너진다.

한계는 먼저 밝힌다. 지적당한 뒤 인정하면 변명이 되고, 먼저 밝히면 근거가 된다.

① 발표에서 가장 강한 수치 세 개 (이건 꼭 넣어라)

수치	값	왜 강한가 / 어떻게 말하나
실제 보이스피싱 녹취 탐지 금감원 「그놈 목소리」 5건	5 / 5 전부 ‘높음’	우리가 만든 대본이 아니라 실제 사기범 통화 다. 게다가 이 5건은 딤페이크가 아니라 진짜 사람 목소리 — 딤페이크 탐지만 하는 솔루션은 한 건도 못 잡는다 . 화법을 주축으로 삼은 근거 그 자체.
정상 대화 헛경보 ‘높음’ 한국어 자유대화 30건	0 % 0 / 30건	정상 대화에 “즉시 통화를 끊으세요”를 띄운 적이 한 번도 없다 . 제품이 쓸 수 없을 만큼 시끄럽지 않다는 증거.
도메인 밖 오탐률 우리가 안 만든 한국어 457문장	1.53 % 7 / 457건	“자기가 만든 문제를 자기가 푼 것 아니냐”에 대한 답. 남이 만든 문장 (Zeroth-Korean, CC BY 4.0)으로 잤다.

이렇게 말하면 된다 — “실제 사기범은 사람이 직접 말합니다. 금융감독원 공개 녹취 5건이 전부 그랬고, 저희는 5건 모두 잡았습니다. 딤페이크 탐지만 하는 방식으로는 이 5건이 하나도 안 잡힙니다. 그래서 저희는 얼굴-목소리보다 화법에 비중을 뒀습니다.”

② 콘텐츠 분석 (화법) — 주 축, 가중치 0.65

2-1. 자체 시나리오 21건 (사기 11 / 정상 10)

분류기	정탐률	오탐률	정확도	비고
순수 키워드 규칙 (개선 전 기준선)	63.6%	30.0%	66.7%	표현이 조금만 달라지면 놓친다
오프라인 분류기 키워드 + 한국어 임베딩	90.9%	10.0%	90.5%	API 키가 없어도 도는 기본 경로
로컬 LLM Qwen2.5-1.5B, 키-설치 불필요	90.9%	10.0%	90.5%	총점은 동물인데 기법별 회수율은 24/41 → 30/41로 더 낮다
OpenAI gpt-4o-mini 기준선 62.5	100%	10.0%	95.2%	아래 주의 필독

출처: docs/validation_report_content.json, _localllm.json, _openai.json · 재현 scripts/validate_content_risk.py

⚠ OpenAI 수치를 인용할 때 — 기준선 62.5는 평가에 쓴 그 21건 위에서 고른 값이라 과적합 소지가 있다. 기본 기준선 50을 쓰면 오탐 30%로 오프라인 분류기(90.5%)보다 **나쁘다**. “OpenAI 95.2%”만 떼어 말하면 안 되고, 표본 21건과 기준선을 그 데이터로 정했다는 점을 함께 밝혀야 한다. 그래서 auto 폴백 체인에도 넣지 않았다.

2-2. 도메인 밖 오탐률 — 우리가 만들지 않은 문장

판정 기준선	오탐 건수	오탐률
30	84 / 457	18.38%
50 (실제 사용값)	7 / 457	1.53%

Zeroth-Korean test split (CC BY 4.0), 뉴스·책 낭독 457문장. 사기와 무관하므로 넘으면 전부 오탐.
출처: docs/validation_report_content_fpr.json · 재현 scripts/validate_content_fpr.py

③ 음성 위조 판별 (AASIST) — 보조 측

조건	정탐률	오탐률	정확도	표본
ASVspoof2019 LA (학습 도메인 안)	97.1%	0.0%	98.3%	120건 진짜50/합성70

⚠️ 학습 도메인 밖에서는 무너진다 (원인 규명 완료)
레벨을 통일해 같은 조건으로 비교하면 이렇게 걸린다 — 음량은 방아쇠일 뿐이고 원인은 도메인 일반화 실패다.

음원 그룹	-39 dB	-30 dB	-25 dB	-20 dB
ASVspoof 진짜 (학습 도메인)	0.8	0.4	0.2	0.3
Zeroth 낭독 (도메인 밖, 진짜 사람)	16.9	81.1	98.9	100.0
실제 통화 녹취 (도메인 밖, 진짜 사람)	45.4	98.1	100.0	100.0

코덱·전화망·재인코딩·편집은 통제 실험으로 전부 기각됐다. 출처: docs/audio_fp_diagnosis.json, validation_report.md 0-7절 · 재현 scripts/diagnose_audio_fp.py

“음성 정확도 98.3%”라고만 말하지 마라. 반드시 “ASVspoof 벤치마크 안에서”를 붙이고, 도메인 밖 한계를 먼저 밝혀라. 결과 화면에도 이 경고가 항상 뜬다.

④ 영상 딥페이크 판별 (FF++ Xception) — 보조 축, 가장 약한 고리

데이터셋	정탐률	오탐률	정확도	표본
FaceForensics++ C23 (학습 도메인 안)	77.3%	2.0%	86.2%	116건 진짜50/가짜66
DFDC (다른 데이터셋 = 안 배운 기법)	70.0%	55.0%	60.0%	50건 진짜20/가짜30

출처: docs/validation_report.json, validation_report_dfdc.json · 재현 scripts/validate_detector.py

⚠️ 영상 수치를 인용할 때는 반드시 “FF++ 기준”을 함께 적어라. DFDC에서 오탐 55%는 사실상 동전 던지기다. 그래서 파이프라인이 영상 결과에 항상 경고를 붙인다.

4-1. “모델을 바꾸면 되지 않나” — 공개 모델 4종을 실제로 재봤다

모델	FF++ 정확도	DFDC 정확도	DFDC 오탐	DFDC 분리도
우리 FF++ Xception	86.2%	60.0%	55%	9.5
dima806/deepfake_vs_real	55%	55%	90%	7.3
prithivMLmods/open-deepfake	55%	60%	50%	-2.1
Wwolf/ViT_Deepfake_Detection	55%	50%	100%	0.5
prithivMLmods/Deep-Fake-Detector-v2	60%	30%	100%	-17.6

분리도 = 가짜 평균점수 - 진짜 평균점수. 음수면 가짜를 진짜보다 더 진짜같이 판정한다는 뜻.

출처: docs/deepfake_model_comparison.json · 재현 scripts/compare_deepfake_models.py

“딥페이크 생성이 탐지보다 빠르는데 어떻게 따라가나요?” 답변용 — “맞습니다. 저희도 실측했습니다. 학습한 기법에서는 오탐 2%인데 다른 데이터셋에서는 55%로 무너집니다. 공개 모델 4종을 다 재봤지만 전부 더 나빴고, 한 모델은 가짜를 진짜보다 더 진짜같이 판정했습니다(분리도 -17.6). 그래서 저희는 그 경쟁에 서비스를 걸지 않았습니다. 딥페이크가 아무리 좋아져도, 돈을 뜯으려면 결국 ‘지금 이체하세요, 아무에게도 말하지 마세요’라고 말해야 합니다. 목적이 안 변하니 설득 화법도 안 변합니다.”

⑤ 교차검증 — 두 축을 합치는 근거

5-1. 시연 3종 (교차검증이 실제로 동작한다는 증거)

샘플	콘텐츠	미디어	통합 점수	등급	무엇을 보여주나
real_normal_call.wav 진짜 사람 + 정상 대화	0.0	26.7	9.3	● 낮음	헛경보가 없다
normal_call.wav 합성 음성 + 정상 대화	0.0	100.0	35.0	● 중간	핵심, 내용은 멀쩡한데 목소리가 합성이라 경고가 뜬다
scam_call.wav 합성 음성 + 사기 화법	100.0	100.0	100.0	● 높음	둘 다 걸려 교차 가산

2026-09-02 OpenAI 백엔드로 재측정해도 세 값이 모두 동일했다.

5-2. 통합 공식·가중치·경계는 격자 탐색으로 정했다 (조합 1,050쌍)

항목	확정값	근거
콘텐츠 / 미디어 가중치	0.65 / 0.35	0.5일 때 놓침 84건 → 0.65일 때 21건. 헛경보는 두 경우 모두 0건

신호등 경계	높음 55 / 중간 30	같은 격자 탐색
통합 공식	곱연산 가산 (DOCX 버전)	기획서 버전A(threshold_bonus)는 임계값에서 +15.2점 계단이 생긴다. 곱연산은 0.24로 매끄럽다 → 정확도가 2.7%p 낮아도 이쪽을 택함
audio / video 결합	max	가중평균은 4조합 중 2개를 놓친다

출처: docs/scoring_decision.json, media_combine_decision.json · 재현 scripts/decide_scoring.py, decide_media_combine.py

5-3. 가중치 0.65의 독립 증거 — 정상 대화 30건

항목	결과	읽는 법
최종 등급 헛경보 ('중간' 이상)	7 / 30 = 23.3%	
그중 '높음'	0 / 30 = 0.0%	최악의 헛경보는 한 번도 없었다
콘텐츠 단독 (임계값 50)	1 / 30 = 3.3%	헛경보의 주범이 음성 엔진이라는 게 수치로 확정됐다. 합성 격자로 정한 0.65를, 전혀 다른 실제 대화 데이터가 같은 방향으로 지지한다
미디어 단독 (임계값 50)	6 / 30 = 20.0%	

KsponSpeech(AI Hub 「한국어 음성」) 자유대화 30건. 검증 목적 소량만 사용, 재배포하지 않음.
한계: 전화가 아니라 대면 자유대화라 전화망 대역·코덱이 없다 — 실제 통화보다 유리한 조건.
출처: docs/validation_report_normal_calls.json · 재현 scripts/validate_normal_calls.py

⑥ 시스템 성능 · 구성 선택

항목	값	근거 / 비교
실시간 처리 속도	오디오 78초를 26~29초에 (약 3배속)	실시간을 따라간다. 모델을 세션 동안 상주시켜 얻은 값 · <code>scripts/test_streaming.py</code>
파일 분석 소요	1분 18초 통화 → 약 33초	STT+화법+RAG+음성 전체
얼굴 검출기	YuNet 100% / Haar 99% (정면)	고개를 돌리면 Haar 84.8%로 떨어져 YuNet을 1순위로 · <code>benchmark_face_detector.py</code>
STT 모델	파일 <code>small</code> / 스트리밍 <code>base</code>	CER·처리시간·노이즈 강건성 실측 · <code>compare_stt_models.py</code>
좌우 반전 TTA	컴	정탐 +3%p, 오탐 동일
RAG 사례 데이터	26건 (기존 18 + 국내 보도 기반 8)	한국어 임베딩(ko-sroberta). 색인 문서 103개

△ RAG 사례를 소개할 때 — 26건 중 실제 기사 인용문은 3건이고, 5건은 보도된 사실관계를 바탕으로 팀이 재구성한 대사다. “실제 판례에서 그대로 가져온 대사”라고 말하면 안 되고, “보도된 수법을 바탕으로 구성했다”고 해야 정확하다. 각 사례의 `source` 필드에 구분해 적어놨다.

⑦ 서비스 범위 — 이 문장으로 통일할 것

온라인에서 처음 만난 상대와의 브라우저 화상통화에서, 대화 화법과 음성·영상 위조를 동시에 보고 통화 중에 경고한다.

통화 유형	통화 중 실시간	통화 후 분석
브라우저 화상통화 (Meet / Zoom / Teams / Whereby)	✅ 크롬 확장 — 통화 페이지 위에 직접 경고	✅ 웹 대시보드
일반 전화 (전화망)	❌ 플랫폼 제약	✅ 녹음 파일 업로드

“보이스피싱은 폰으로 일어나는데 웹으로 어떻게 하나요?” 답변용 — “저희가 만든 건 분석 엔진입니다. 오디오만 있으면 통화 종류를 가리지 않습니다. 검증에 쓴 금감원 녹취 5건은 전부 일반 전화 통화였고 5건 다 잡았습니다.
문제는 엔진이 아니라 입구입니다. 폰 통화 오디오는 iOS가 앱 접근을 막고, 안드로이드도 Android 10 이후 서드파티 통화 녹음을 제한합니다. 앱으로 만들어도 똑같습니다 — 통화 중 실시간은 제조사나 통신사만 할 수 있는 영역입니다.
그래서 지금 접근 가능한 입구부터 만들었습니다. 엔진과 입구를 분리해 설계했으므로 통신사·제조사와 연계되면 입구만 바꿔 끼우면 됩니다. 저희가 B2B·공공 협업을 다음 단계로 잡은 이유입니다.”

간판 / 근거 / 확장을 섞지 마라 — 간판은 화상통화. 보이스피싱(전화)은 “엔진이 실제 사기 통화에서 검증됐다”는 근거로, 로맨스 스캠은 “온라인에서 처음 만난 상대와의 화상통화”에 포함되는 확장 사례로 둔다. 셋을 나란히 간판에 걸면 말한 범위와 시연이 어긋나 완성도 항목에서 깎인다.

⑧ 심사 배점과의 연결 (자유과제)

배점	항목	우리가 여기에 쓸 카드
30	완성도 기획한 아이디어를 충실히 달성 / 안정적 구동	말한 범위(화상통화)와 시연이 일치. 실시간 3배속 실측, 확장 자동 검증 통과
30	사용자 친화성 직관적·유용하게 전달 / 편의성	시연 3분에 전부 걸려 있다. 설치 없이 탭 공유, 통화 화면 위 오버레이, 안전하면 아무것도 안 뜸, 점수만이 아니라 근거 제시

20	참신성	화법 + 미디어 교차검증 . "탐지 경쟁에 서비스를 걸지 않는다"는 설계 판단
20	효과성	금감원 실제 녹취 5/5, 데이터 로드맵(AI Hub·공공데이터·가명화), B2B·공공 연계

발표 10분 이내 · 질의응답 5분 · 원칙적으로 팀장 발표

⑨ 절대 하지 말 것

- “영상 딥페이크 정확도 86.2%”만 말하기. → 반드시 “FF++ 기준”을 붙이고 DFDC 55%를 함께 밝힌다.
- “음성 정확도 98.3%”만 말하기. → “ASVspoof 벤치마크 안에서”를 붙인다.
- “OpenAI 95.2%”만 말하기. → 표본 21건 + 기준선을 그 데이터로 정했다는 점을 함께.
- RAG 사례를 “실제 판례 대사”라고 소개하기. → “보도된 수법을 바탕으로 구성”.
- ViT 백엔드 수치 인용하기. → 판별력이 검증되지 않았다. 정식 경로는 FF++뿐.
- “음성 엔진은 도메인에 강하다”고 말하기. → 정반대다.

전체 측정 조건과 재현 절차: docs/validation_report.md · 시연 순서와 예상 질문: docs/demo_guide.md · 데이터 확보 계획: docs/data_roadmap.md