

DualGuard — 예상 질의응답

2026-09-03 · 제8회 K-디지털 트레이닝 해커톤 자유과제 · 발표 10분 / 질의응답 5분
제출된 PPT 18장을 그대로 읽고 정리했다. 답변 문안은 그대로 말해도 되게 썼다.

△ 발표 전에 팀이 반드시 확인할 것 — PPT 수치와 저장소 검증 리포트가 어긋난다
아래 세 가지는 심사위원이 근거를 물으면 바로 드러난다. 말을 맞춰두고 들어가야 한다.

항목	PPT (11·9쪽)	저장소 리포트	어떻게 할 것인가
영상 정확도	84.0% · 오탐 0.0% FF++ C23 50건 (5-겹)	86.2% · 오탐 2.0% FF++ C23 116건	PPT가 구버전(8/6 최초 측정 50건)이다. 검증셋을 116건으로 늘린 뒤 값이 바뀌었다. 말할 때는 116건 기준으로 하고, 슬라이드 숫자를 고칠 수 있으면 고칠 것.
음성 표본	98.0% · ASVspoof 50건	98.3% · ASVspoof 120건 (진짜 50 / 합성 70)	"50건"은 진짜 음성 개수만 센 것으로 보인다. 전체는 120건이다.
"오탐 0건"	세 엔진 합산 0건	영상 오탐 2.0%(50건 중 1건) 콘텐츠 오탐 10.0% (10건 중 1건)	이건 그대로 두면 위험하다. "오탐 0건"은 현재 리포트로 뒷받침되지 않는다. 아래 Q-1 답변대로 먼저 정정해서 말하는 편이 낫다.
교차 가산점	"+15점, 두 점수가 모두 70을 넘을 때"	확정 공식은 곱연산 가산 (+15 방식은 기각)	기획서 두 버전을 다 구현해 비교했고, +15 방식은 임계값에서 15.2점 계단이 생겨 탈락시켰다. 코드는 곱연산으로 돈다. PPT 설명과 실제 동작이 다르다 — Q-2 답변 참고.

가장 안전한 대응 — 슬라이드를 못 고치면, 해당 슬라이드에서 말로 한 줄 덧붙여라.
"이 수치는 초기 50건 기준이고, 이후 116건으로 늘려 다시 측정한 값은 86.2%입니다. 오탐은 0이 아니라 영상 2%입니다." — 스스로 정정하면 오히려 신뢰가 올라간다.

1. 어긋난 부분에 대한 질문 (제일 먼저 준비)

- Q-1. 11쪽 "오탐 0건이라고 하셨는데, 정말 한 건도 없습니까?"

먼저 정정하겠습니다. 슬라이드에는 0건으로 적혀 있는데, 저희 검증 리포트 기준으로는 영상 엔진 오탐이 2.0%입니다. 진짜 얼굴 50건 중 1건을 가짜로 판정했습니다. 콘텐츠 분류도 정상 대화 10건 중 1건을 오판했습니다.
음성은 ASVspoof 120건에서 오탐 0%가 맞습니다. 세 엔진을 합쳐 0건이라고 쓴 건 저희 표기 실수이고, 정확한 값은 리포트에 그대로 공개돼 있습니다.
- Q-2. 10쪽 "교차 가산점 +15점은 어떻게 계산되니까?"

기획서에 통합 공식이 두 버전 있어서 둘 다 구현하고 비교했습니다. 슬라이드에 적힌 +15점 방식은 그중 한 버전인데, 실측해 보니 임계값 근처에서 점수가 15.2점 갑자기 뛰는 계단이 생겼습니다. 사용자 입장에서 "1점 차이로 등급이 확 바뀌는" 현상이라, 실제 코드는 매끄러운 곱연산 방식(계단 0.24)으로 돌고 있습니다. 정확도는 2.7%p 낮지만 그쪽을 택했습니다.
- Q-3. 11쪽 "검증 데이터가 50건씩이면 너무 적지 않습니까?"

맞습니다. 그래서 이후에 늘렸습니다. 영상은 116건, 음성은 120건으로 다시 측정했고 그 값이 지금 저희가 인용하는 수치입니다. 여기에 더해 우리가 만들지 않은 데이터로 따로 잰습니다 — 한국어 낭독 457문장에서 오탐 1.53%, 한국어 자유대화 30건에서 '높음' 헛경보 0%, 다른 데이터셋(DFDC) 영상 50건으로 크로스도메인까지 봤습니다. 전부 합해 799건입니다.

2. 슬라이드별 예상 질문

3쪽 "1,300%, 3,116억 — 출처가 어디입니까?"

슬라이드 하단에 적어둔 대로 **Pindrop 2024 보고서**, **경찰청 국가수사본부**, **국정원 111센터** 자료입니다. 저희가 만든 수치가 아니라 공개 통계를 인용했습니다.

발표자 확인 — 이 세 숫자는 외부 통계라 우리 리포트로 뒷받침되지 않는다. 질문이 깊어지면 **"인용 자료라 저희가 재현한 값은 아닙니다"**라고 선을 그어라.

4쪽 "홍콩 340억, 캄보디아 120억 사건이 우리 서비스로 막혔을까요?"

홍콩 사례는 **화상회의 참석자 전원이 딥페이크**였습니다. 저희 미디어 엔진이 반응할 수 있는 유형이지만, **영상 판별은 학습 도메인 밖에서 신뢰도가 떨어집니다**. 다만 그 통화에도 "지금 송금하라"는 화법이 있었고, **저희는 그쪽을 주 신호로 봅니다**. 100% 차단이 아니라 **가장 이른 순간에 의심 신호를 띄우는 것**이 목표입니다.

5쪽 "통신 3사가 하면 우리는 어떻게 됩니까?"

통신사는 **망에 접근할 수 있어서 근본적으로 유리한 위치**입니다. 저희가 그걸 이기려는 게 아닙니다. 통신사는 대형 플랫폼 중심이라 **개인 채널까지 오는 데 시간이 걸리고**, 저희는 **설치 없이 브라우저만으로 지금 쓸 수 있습니다**. 중장기적으로는 경쟁이 아니라 **B2B API로 그쪽에 들어가는 것**이 저희 전략입니다(17쪽).

6·7쪽 "탭 공유만으로 정말 설치가 필요 없습니까?"

네. 브라우저 표준 API(`getDisplayMedia`)를 씁니다. 사용자는 공유할 탭을 고르고 **"탭 오디오 공유"만 체크**하면 됩니다. 경고는 **항상 위에 뜨는 작은 창**으로 통화 화면 위에 표시되므로 저희 사이트로 돌아올 필요가 없습니다. 브라우저 확장 버전도 만들었지만, 그건 설치가 필요해서 오늘 시연은 설치 없는 경로로 보여드렸습니다.

8쪽 "RAG 데이터에 영화·드라마 대사가 들어갔는데, 그게 실제 사기와 같습니까?"

중요한 지적입니다. 저희 참조 사례 26건 중 **실제 기사 인용문은 3건**이고, 나머지는 **보도된 수법을 바탕으로 팀이 재구성한 대사**입니다. 각 사례의 출처 필드에 **"기사 인용문 / 사실관계 기반 재구성 / 실제 대사 아님"**으로 구분해 적어놨습니다. 실제 통화 대사를 그대로 인용한 공개 자료가 거의 없어서 그렇게 했고, 그 한계를 문서에 명시했습니다.

절대 하지 말 것 — "실제 판례에서 그대로 가져온 대사"라고 말하면 안 된다. **"보도된 수법을 바탕으로 구성했다"**가 정확한 표현이다.

9쪽 "음성 98%면 거의 완벽한데, 실제 통화에서도 그렇습니까?"

아닙니다. 그게 저희가 가장 크게 부딪힌 한계입니다. 98.3%는 **ASVspoof 벤치마크 안에서**의 값이고, **학습 도메인 밖** 음성엔 진짜 목소리도 합성으로 판정합니다.

원인까지 규명했습니다. 코덱·전화망·재인코딩·편집을 하나씩 통제해 실험했고 전부 기각했습니다. 남은 건 **도메인 일반화 실패**였습니다. 레벨을 맞춰 비교하면 학습 도메인 안 음성은 0점대인데 밖은 100까지 올라갑니다.

그래서 미디어 가중치를 0.35로 낮추고, 결과 화면에 이 경고를 항상 띄웁니다.

12쪽 "3중 방어선의 3단계는 결국 사람이 판단하라는 거 아닙니까?"

맞습니다. 그게 **의도한 설계**입니다. 오탐이 사람에게 피해를 줄 수 있는 영역이라 **자동 차단을 하지 않습니다**. 저희는 "이 구간에서 이런 표현이 나왔고, 유사 사례가 이것"이라는 근거를 제시하고, 판단과 신고는 사용자가 하도록 했습니다. 결과도 "확정"이 아니라 **"위험 가능성 약 00%"**로 표현합니다.

15쪽 "시연 영상 말고 지금 바로 돌려볼 수 있습니까?"

네, 가능합니다. (→ 서버가 떠 있는지, 세션이 비어 있는지 미리 확인해 둘 것)

발표자 확인 — 라이브 시연을 하겠다고 답하려면 **서버 기동 + 실시간 세션이 비어 있는 상태**여야 한다. 세션이 하나 물려 있으면 새 세션이 막히고, 자동 해제까지 **약 90초**가 걸린다. 확답 전에 화면을 한 번 보고 말할 것.

17쪽 "기본 기능 무료면 수익은 언제 납니까?"

개인용을 무료로 푸는 건 **신종 사기 패턴을 모으기** 위해서입니다. 그 데이터가 쌓일수록 B2B·공공 채널의 정확도가 올라가고, 매출은 그쪽에서 납니다. 콜센터·저축은행·2금융권 대상 **API 사용량 과금**이 1차 모델입니다. 지금 저희 성능의 한계도 결국 **데이터**라서, 수익 구조와 성능 개선이 같은 방향입니다.

18쪽 "로맨스 스캠이 첫 진입점이라고 했는데, 그쪽 검증은 얼마나 했습니까?"

솔직히 말씀드리면 **참조 사례 26건 중 로맨스 유형은 2건**으로 많지 않습니다. 저희가 실제로 검증한 건 **기관 사칭형 통화**가 중심입니다. 다만 엔진이 보는 것은 **설득 화법의 구조**라서 유형에 종속되지 않고, 로맨스 스캠은 "온라인에서 처음 만난 상대와의 화상통화"에 포함돼 같은 구조로 커버됩니다. **유형별 특화는 데이터를 더 모아야 할 다음 단계**로 보고 있습니다.

3. 공통 질문 (슬라이드와 무관하게 나온다)

"보이스피싱은 폰으로 일어나는데, 웹으로 어떻게 하나요?" ← 최다 예상

저희가 만든 건 **분석 엔진**입니다. 오디오만 있으면 통화 종류를 가리지 않습니다 — 검증에 쓴 금융감독원 공개 녹취 5건은 전부 **일반 전화 통화**였고 5건 다 잡았습니다.
문제는 엔진이 아니라 **입구**입니다. 폰 통화 오디오는 iOS가 앱 접근을 막고, 안드로이드도 Android 10 이후 서드파티 통화 녹음을 제한합니다. **앱으로 만들어도 똑같습니다** — 통화 중 실시간은 제조사나 통신사만 할 수 있습니다.
그래서 **지금 접근 가능한 입구부터** 만들었습니다. 엔진과 입구를 분리해 설계했으므로, 통신사-제조사와 연계되면 **입구만 바꿔 끼우면 됩니다**.

"딥페이크 생성이 탐지보다 빠르는데 어떻게 따라잡니까?"

맞습니다. **저희도 실측했습니다**. 학습한 기법에서는 오탐 2%인데 다른 데이터셋(DFDC)에서는 **55%로 무너집니다**. 공개 모델 4종을 전부 다시 재봤는데 **전부 더 나빴고**, 한 모델은 가짜를 진짜보다 더 진짜같이 판정했습니다.
그래서 저희는 **그 경쟁에 서비스를 걸지 않았습니다**. 딥페이크가 아무리 좋아져도 돈을 뜯으려면 결국 "지금 이체하세요, 아무에게도 말하지 마세요"라고 말해야 합니다. **목적이 안 변하니 설득 화법도 안 변합니다**. 그게 화법에 0.65를 준 이유입니다.

"당하는 사람이 그걸 켜겠습니까?"

맞습니다. 의심했으면 안 당하죠. 그래서 **의심될 때 켜는 게 아니라 켜두는 방식**으로 만들었습니다. 화상통화를 시작하면 계속 돌고, **안전할 땐 아무것도 안 보입니다**. 위험할 때만 화면에 올라옵니다.

"실제 사기 통화에서도 됩니까?" ← 먼저 던져도 좋은 카드

네. 금융감독원이 공개한 **실제 사기범 통화 녹취 5건**을 그대로 넣었고 **5건 모두 '녹음'으로 경고했습니다**. 저희가 만든 대본이 아닙니다.
그리고 이 5건은 전부 **사람이 직접 말한 통화**입니다 — 딥페이크 탐지만 하는 솔루션은 **한 건도 못 잡습니다**. 저희가 대화 내용을 함께 보는 이유입니다.

"통화 녹음을 다루는데 개인정보 문제는요?"

업로드한 **원본 파일은 분석 후 즉시 삭제**하고 결과만 보관합니다. 화면에도 "본인이 참여한 통화만 분석에 사용하라"고 명시합니다. 검증에 쓴 데이터는 공개 코퍼스와 금융감독원이 공익 목적으로 공개한 자료입니다.

"직접 학습한 모델이 있습니까?"

없습니다. 공개 모델을 조합하고 **한국어 통화 도메인에서 검증·보정한 것**이 저희 기여입니다. 점수 재척도 파라미터와 가중치(0.65/0.35), 신호등 경계(55/30)는 **1,050쌍 격자 탐색**으로 저희가 적합했습니다.

4. 질문이 없을 때 먼저 던질 것

한 가지 먼저 말씀드리면, 저희 **영상 엔진은 학습 데이터 밖에서 오탐률이 55%까지** 올라갑니다. 저희가 직접 재서 확인한 값이고, 공개 모델 4종을 다시 재봐도 전부 더 나빴습니다. 딥페이크 탐지 분야 전체의 한계라고 보고 있고, 그래서 저희는 **화법을 주 축으로 두는 구조**를 택했습니다. 이 수치를 숨기지 않는 게 저희 팀이 가장 신경 쓴 부분입니다.

5. 절대 하지 말 것

- ❌ "오탐 0건"이라고 말하기 → 영상 2.0%, 콘텐츠 10.0%가 있다. 먼저 정정하는 게 낫다
- ❌ "영상 정확도 84%/86.2%"만 말하기 → 반드시 "**FF++ 기준**" + DFDC 오탐 55% 함께
- ❌ "음성 98%"만 말하기 → "**ASVspoof 벤치마크 안에서**" 반드시 붙이기
- ❌ RAG 사례를 "실제 판례 대사"라고 소개하기 → "보도된 수법 기반 구성"
- ❌ "교차 가산점 +15점" 설명하기 → 실제 코드는 **곱연산**이다
- ❌ 모르는 걸 지어내기 → "**그건 아직 못 했습니다**"가 훨씬 낫다

수치 빠른 참조 (저장소 리포트 기준)

항목	값	조건 — 이걸 꼭 같이 말할 것
----	---	-------------------

화법 분류	90.5%	자체 시나리오 21건, API 키 없이
음성 합성 판별	98.3% (118/120)	ASVspoof 벤치마크 안 . 밖에서는 무너짐
영상 딥페이크	86.2% / 오탐 2.0%	FF++ 116건 안
영상 크로스도메인	오탐 55%	DFDC 50건 — 먼저 밝힐 것
도메인 밖 오탐	1.53% (7/457)	Zeroth-Korean, 우리가 안 만든 문장
정상 대화 헛경보	'높음' 0% (0/30)	KsponSpeech 자유대화
실제 사기 녹취	5 / 5	금감원 「그놈 목소리」
전체 검증	799건	7개 리포트 합산
실시간 속도	3배속	오디오 78초를 26~29초에
가중치 / 경계	0.65·0.35 / 55·30	격자 1,050쌍 (PPT와 일치)